

第十章 核回归、核方法与相似性学习

10.5 核技巧：从显式映射到核函数

核函数在不同方法中承担的作用并不完全相同。在 Nadaraya–Watson 核回归中，核值被直接用作局部加权系数；在核岭回归、支持向量机等核方法中，核函数则表示某个特征空间中的内积。为了说明后一种用法，本节先介绍核技巧以及有效核函数需要满足的条件。

10.5.1 为什么可以用核函数代替显式特征映射

设原始样本为 $\mathbf{x} \in \mathbb{R}^d$ ，通过映射

$$\phi: \mathbb{R}^d \rightarrow \mathcal{H}$$

进入特征空间 $\mathcal{H}$ 。在该空间中，线性模型可以写成

$$f(\mathbf{x}) = \langle \mathbf{w}, \phi(\mathbf{x}) \rangle_{\mathcal{H}}.$$

许多线性学习算法经过对偶化后，只通过样本间的内积


$$\langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_{\mathcal{H}}$$

使用映射后的特征，而不需要逐个读取 $\phi(\mathbf{x})$ 的坐标。若存在函数 k 满足

$$k(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_{\mathcal{H}}, \quad (10.1)$$

则可以直接计算 $k(\mathbf{x}, \mathbf{z})$ ，而不显式构造高维特征向量。这种以核函数替代特征空间内积的计算方式称为核技巧。

需要强调的是，核技巧并不是取消了特征映射。算法仍然等价于在特征空间 $\mathcal{H}$ 中进行学习，只是映射后的坐标被隐含在核函数中。



省去对高维特征坐标的显式构造与存储

图 10.1: 显式特征映射与核技巧的两条计算路径。二者得到相同的特征空间内积，但核技巧不显式构造高维坐标。

10.5.2 Gram 矩阵与半正定条件

给定训练样本 $\{\mathbf{x}_i\}_{i=1}^n$ ，先把映射后的特征向量按行排列，构成特征矩阵

$$\Phi = \begin{bmatrix} \phi(\mathbf{x}_1)^\top \\ \phi(\mathbf{x}_2)^\top \\ \vdots \\ \phi(\mathbf{x}_n)^\top \end{bmatrix}.$$

其中，矩阵 Φ 的第 i 行就是样本 $\mathbf{x}_i$ 在特征空间中的坐标。用该矩阵乘以自身的转置，得到

$$\mathbf{K} = \Phi\Phi^\top, \quad K_{ij} = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) = k(\mathbf{x}_i, \mathbf{x}_j). \quad (10.2)$$

因此， $\mathbf{K}$ 的第 i 行、第 j 列记录样本 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 的核值，这就是 Gram 矩阵。

为了说明半正定条件，任取系数向量

$$\mathbf{a} = (a_1, a_2, \dots, a_n)^\top.$$

特征矩阵的转置乘以 $\mathbf{a}$ ，等于对所有样本的特征向量进行线性组合：

$$\Phi^\top \mathbf{a} = \sum_{i=1}^n a_i \phi(\mathbf{x}_i). \quad (10.3)$$

将式 (10.2) 和式 (10.3) 代入二次型，可得

$$\begin{aligned} \mathbf{a}^\top \mathbf{K} \mathbf{a} &= \mathbf{a}^\top \Phi \Phi^\top \mathbf{a} \\ &= (\Phi^\top \mathbf{a})^\top (\Phi^\top \mathbf{a}) \\ &= \|\Phi^\top \mathbf{a}\|_{\mathcal{H}}^2 \\ &= \left\| \sum_{i=1}^n a_i \phi(\mathbf{x}_i) \right\|_{\mathcal{H}}^2 \geq 0. \end{aligned}$$

最后一项是特征空间中某个向量的长度平方，因此不可能小于零。由此可见，合法核函数所生成的 Gram 矩阵必须是半正定矩阵。

反过来，若函数 k 是对称函数，并且对任意有限样本集合，其 Gram 矩阵都满足

$$\mathbf{a}^\top \mathbf{K} \mathbf{a} \geq 0, \quad \forall \mathbf{a} \in \mathbb{R}^n,$$

则 k 可以被解释为某个希尔伯特空间中的内积核。这是机器学习中判定核函数是否合法时最常用的条件。

Mercer 定理与半正定条件。 在输入空间紧致、核函数连续且对称等附加条件下，Mercer 定理进一步给出核函数的特征展开

$$k(\mathbf{x}, \mathbf{z}) = \sum_{m=1}^{\infty} \lambda_m \psi_m(\mathbf{x}) \psi_m(\mathbf{z}), \quad \lambda_m \geq 0. \quad (10.4)$$

由此可以构造

$$\phi(\mathbf{x}) = (\sqrt{\lambda_1} \psi_1(\mathbf{x}), \sqrt{\lambda_2} \psi_2(\mathbf{x}), \dots)^\top.$$

需要注意，Mercer 定理是在附加正则条件下给出的谱分解结果；在一般的核方法表述中，更直接的有效性标准是“任意有限样本产生的 Gram 矩阵均为半正定矩阵”。二者不宜写成彼此独立的两套条件。




图 10.2: Gram 矩阵集中表示训练样本之间的两两核值。颜色深浅仅用于示意数值大小。

10.5.3 核技巧的适用范围与计算代价

核技巧要求原算法能够改写为只依赖样本内积的形式，同时要求所采用的函数是合法的半正定核。任意相似度函数并不一定能够直接用于核方法：函数在数值上非负，并不能保证其 Gram 矩阵半正定；反之，合法核也不要求对任意样本对都取非负值，例如线性核 $k(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z}$ 可以取负值。

核技巧将计算重点从显式特征维度转移到训练样本之间的两两关系。若训练样本数为 n ，完整核矩阵需要 $O(n^2)$ 的存储空间，直接求解某些核方法还可能需要 $O(n^3)$ 的时间。因此，核技巧主要解决高维特征的显式构造问题，并不会自动解决大样本计算问题。

表 10.1: 显式特征映射与核技巧的比较

比较维度	显式特征映射	核技巧
主要表示	保存每个样本映射后的高维坐标	保存或按需计算样本之间的核值
适合情形	映射维度可控，且需要直接使用或解释特征	特征空间很高，但核函数容易直接计算
主要优势	可以直接使用常规线性学习流程	避免显式构造大量高阶特征
主要代价	特征数可能随多项式阶数迅速增长	完整核矩阵通常需要 $O(n^2)$ 存储
计算瓶颈	主要受映射后特征维度影响	主要受训练样本数量影响

10.6 两类基于核的回归方法

“核回归”在不同文献中有狭义和广义两种用法。非参数统计中的核回归通常指利用核函数进行局部平滑的回归方法，Nadaraya–Watson 回归是其中最基本的形式；机器学习中的核方法回归则把核函数作为特征空间内积，核岭回归是典型代表。二者都利用训练样本与预测点之间的核值，但核函数的含义、系数的产生方式和模型的训练过程并不相同。

不建议简单地把 Nadaraya–Watson 回归称为“非参数模型”、把核岭回归称为“参数模型”。前者确实属于非参数局部平滑方法；核岭回归在固定有限维特征映射下等价于参数化岭回归，但使用高斯核等无限维核时，通常也被归入非参数核方法。更准确的区分是“局部核加权”与“特征空间中的全局正则化学习”。

10.6.1 Nadaraya–Watson 核回归：把核函数作为局部权重

设训练集为

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n.$$

对于新样本 $\mathbf{x}$, Nadaraya–Watson 核回归的预测为

$$\hat{y}_{\text{NW}}(\mathbf{x}) = \frac{\sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i) y_i}{\sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i)}, \quad (10.5)$$

其中, K_h 是带宽为 h 的平滑核。常见写法为

$$K_h(\mathbf{u}) = h^{-d} K(\mathbf{u}/h).$$

在式 (10.5) 的比值中, 分子和分母的公共比例因子会相互抵消。

定义预测点相关的归一化权重

$$\omega_i(\mathbf{x}) = \frac{K_h(\mathbf{x} - \mathbf{x}_i)}{\sum_{j=1}^n K_h(\mathbf{x} - \mathbf{x}_j)}, \quad (10.6)$$

则

$$\hat{y}_{\text{NW}}(\mathbf{x}) = \sum_{i=1}^n \omega_i(\mathbf{x}) y_i. \quad (10.7)$$

当 K_h 非负时, $\omega_i(\mathbf{x}) \geq 0$ 且 $\sum_i \omega_i(\mathbf{x}) = 1$, 因此预测值是局部训练标签的加权平均。

Nadaraya–Watson 估计也可以从局部加权最小二乘得到。对每一个预测位置 $\mathbf{x}$, 求解

$$\hat{\beta}_0(\mathbf{x}) = \arg \min_{\beta_0} \sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i) (y_i - \beta_0)^2. \quad (10.8)$$

其解正是式 (10.5)。因此, Nadaraya–Watson 回归也称为零阶局部多项式回归或局部常数回归。




图 10.3: Nadaraya–Watson 回归通过局部核值分配预测权重。圆点大小表示训练样本对新样本预测的相对影响。

假设新样本与三个训练样本的核值分别为

$$K_h(\mathbf{x} - \mathbf{x}_1) = 0.8, \quad K_h(\mathbf{x} - \mathbf{x}_2) = 0.5, \quad K_h(\mathbf{x} - \mathbf{x}_3) = 0.2,$$

对应标签为 $y_1 = 2$ 、 $y_2 = 5$ 、 $y_3 = 8$ 。则

$$\hat{y}_{\text{NW}}(\mathbf{x}) = \frac{0.8 \times 2 + 0.5 \times 5 + 0.2 \times 8}{0.8 + 0.5 + 0.2} = 3.8.$$

这个例子体现了 Nadaraya–Watson 回归的计算过程：先根据预测点计算局部核值，再进行归一化，最后对原始标签加权求和。

带宽 h 控制局部邻域的范围。 h 较小时，模型主要依赖距离预测点很近的样本，拟合曲线变化较快； h 较大时，更多远距离样本参与预测，结果更平滑。实际应用中还需注意特征尺度、边界偏差、分母过小和逐样本预测成本等问题。

10.6.2 核岭回归：把核函数作为特征空间内积

核岭回归首先把输入映射到特征空间，再在该空间中进行带 L_2 正则项的岭回归。其原始形式为

$$\min_{\mathbf{w}} \sum_{i=1}^n [y_i - \langle \mathbf{w}, \phi(\mathbf{x}_i) \rangle_{\mathcal{H}}]^2 + \lambda \|\mathbf{w}\|_{\mathcal{H}}^2, \quad \lambda > 0. \quad (10.9)$$

根据表示定理，最优函数可以表示为训练样本核函数的线性组合：

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}_i, \mathbf{x}). \quad (10.10)$$

令核矩阵 $\mathbf{K}$ 满足 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ ，标签向量为 $\mathbf{y} = (y_1, \dots, y_n)^\top$ ，则系数向量为

$$\boldsymbol{\alpha} = (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}. \quad (10.11)$$

对于新样本 $\mathbf{x}$ ，定义

$$\mathbf{k}_x = (k(\mathbf{x}_1, \mathbf{x}), \dots, k(\mathbf{x}_n, \mathbf{x}))^\top,$$

则预测为

$$\hat{y}_{\text{KRR}}(\mathbf{x}) = \mathbf{k}_x^\top (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y} = \mathbf{k}_x^\top \boldsymbol{\alpha}. \quad (10.12)$$

与 Nadaraya–Watson 回归不同，核岭回归中的 $\boldsymbol{\alpha}$ 是利用全部训练样本、全部标签和核矩阵共同求得的全局系数，训练完成后不会随预测点改变。预测点只通过 $\mathbf{k}_x$ 影响最终结果。核岭回归也可以写成标签的加权和

$$\hat{y}_{\text{KRR}}(\mathbf{x}) = \mathbf{s}(\mathbf{x})^\top \mathbf{y}, \quad \mathbf{s}(\mathbf{x})^\top = \mathbf{k}_x^\top (\mathbf{K} + \lambda \mathbf{I})^{-1},$$

但这些等效权重通常不要求非负，权重之和也不一定等于 1。因此，核岭回归不能解释为简单的局部标签平均。

正则化参数 λ 控制拟合误差与函数复杂度之间的平衡。 λ 较小时，模型更强调拟合训练数据； λ 较大时，模型系数受到更强约束。若使用高斯核，模型通常还包含核宽度参数，核宽度控制样本在特征空间中的相似范围，而 λ 控制全局正则化强度。

表 10.2: Nadaraya–Watson 核回归与核岭回归的比较

比较维度	Nadaraya–Watson 核回归	核岭回归
基本思想	在预测点附近对训练标签进行局部加权平均	在核定义的特征空间中求解带正则项的全局最小二乘问题
核函数的作用	生成预测点相关的局部权重	表示特征空间中的内积
典型公式	$\hat{y}(\mathbf{x}) = \sum_i \omega_i(\mathbf{x}) y_i$	$\hat{y}(\mathbf{x}) = \mathbf{k}_{\mathbf{x}}^{\top} (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$
系数的产生方式	对每个预测点重新计算并归一化	通过全部训练样本和标签一次性全局求解
权重性质	使用非负核时，权重非负且和为 1	等效权重可为负，权重之和通常不等于 1
是否要求半正定核	作为局部平滑权重时通常不要求满足 Mercer 核条件	必须使用能够产生半正定 Gram 矩阵的合法核
主要超参数	带宽 h	正则化参数 λ 以及核参数
训练与预测	几乎无显式训练，但预测通常需要访问全部训练样本	训练需解核矩阵线性方程，预测需与训练样本计算核值
方法性质	局部、非参数平滑	全局正则化核方法；有限维映射下等价于参数化岭回归，常用无限维核下通常视为非参数方法

10.6.3 两种方法的比较

由表 10.2 可见，两种方法的共同点只是预测都涉及样本间的核值。Nadaraya–Watson 回归直接把核值归一化为局部权重；核岭回归则先利用完整 Gram 矩阵求得全局系数，再通过核函数完成预测。前者的关键控制量是带宽，后者同时受到核参数和正则化参数的影响。

10.6.4 术语范围

在非参数统计语境中，“核回归”通常主要指 Nadaraya–Watson 回归、局部线性回归和局部多项式回归等核平滑方法。在机器学习语境中，“基于核的回归方法”还可以包括核岭回归、支持向量回归和高斯过程回归等。为避免混淆，本文将前一类称为“核平滑回归”，将后一类称为“核方法回归”。