

第十二章 聚类分析与无监督学习

12.6 谱聚类的基本思想

K-means 直接在特征空间中比较样本到簇中心的距离，因此更擅长发现近似球形、尺度相近的簇。当数据形成弯月、环形或其他非凸结构时，同一簇中的两个样本可能在欧氏空间中相距较远，却能通过一系列局部相似的样本彼此连通。谱聚类（spectral clustering）正是从这种“局部连接形成整体簇”的观点出发，把聚类转化为图划分问题。

谱聚类的主线可以概括为

样本 $\rightarrow$ 相似图 $\rightarrow$ 图拉普拉斯 $\rightarrow$ 谱嵌入 $\rightarrow$ 常规聚类。

其中“谱”指矩阵的特征值和特征向量。谱聚类不是直接在原始坐标上分组，而是先利用图拉普拉斯矩阵的特征向量学习一个低维表示，再在该表示中完成聚类。

12.6.1 从样本到相似图

设数据集为

$$\mathcal{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \quad \mathbf{x}_i \in \mathbb{R}^d.$$

把每个样本看作图中的一个节点，得到加权无向图

$$G = (V, E, \mathbf{W}),$$

其中 V 是节点集合， E 是边集合， $\mathbf{W} = [w_{ij}]$ 是相似度矩阵。元素 w_{ij} 表示样本 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 的连接强度。常用的高斯相似度为

$$w_{ij} = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|_2^2}{2\sigma^2}\right), \quad i \neq j, \quad (12.1)$$

并令 $w_{ii} = 0$ 。带宽 σ 控制相似性随距离衰减的速度。

如果对所有样本对都计算式 (12.1)，就得到完全图；在实际任务中，更常见的做法是只保留局部边，例如：

- **k 近邻图**：仅连接每个样本与其 k 个近邻，再将图对称化；

- ε 邻域图：仅连接距离不超过 ε 的样本；
- 自适应邻域图：根据局部密度为不同样本设置不同尺度。




图 12.1: 谱聚类把样本组织成相似图。即使簇呈非凸形状，只要簇内局部连接较强、簇间连接较弱，图划分仍能恢复其结构。

图 12.1 展示了谱聚类与 K-means 的主要差别。谱聚类关心的不是能否用一个中心代表全部样本，而是能否在尽量切断弱连接的同时保留强连接。

12.6.2 度矩阵与图拉普拉斯矩阵

节点 i 的加权度定义为与它相连的全部边权之和：

$$d_i = \sum_{j=1}^n w_{ij}. \quad (12.2)$$

把各节点度数放在对角线上，得到度矩阵

$$\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_n).$$

最基本的非归一化图拉普拉斯矩阵为

$$\mathbf{L} = \mathbf{D} - \mathbf{W}. \quad (12.3)$$

图拉普拉斯矩阵把“相邻节点的表示应当接近”写成了一个二次型。对于任意向量 $\mathbf{f} = (f_1, \dots, f_n)^\top$ ，有

$$\begin{aligned} \mathbf{f}^\top \mathbf{L} \mathbf{f} &= \mathbf{f}^\top (\mathbf{D} - \mathbf{W}) \mathbf{f} \\ &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{ij} (f_i - f_j)^2 \geq 0. \end{aligned} \quad (12.4)$$

若两个节点的边权 w_{ij} 很大, 而 f_i 与 f_j 差异也很大, 式 (12.4) 就会受到较大惩罚。因此, 较小的拉普拉斯二次型对应“在强连接边上变化平缓”的节点表示。

由式 (12.4) 可知, $\mathbf{L}$ 是半正定矩阵, 所有特征值都非负。此外,

$$\mathbf{L}\mathbf{1} = \mathbf{0},$$

所以常数向量 $\mathbf{1}$ 是特征值 0 对应的特征向量。图中有几个连通分量, 特征值 0 的重数就是几; 这正是拉普拉斯谱能够反映图连通结构的原因。

为了减弱节点度数差异带来的影响, 常使用两种归一化拉普拉斯矩阵:

$$\mathbf{L}_{\text{sym}} = \mathbf{D}^{-1/2} \mathbf{L} \mathbf{D}^{-1/2} = \mathbf{I} - \mathbf{D}^{-1/2} \mathbf{W} \mathbf{D}^{-1/2}, \quad (12.5)$$

$$\mathbf{L}_{\text{rw}} = \mathbf{D}^{-1} \mathbf{L} = \mathbf{I} - \mathbf{D}^{-1} \mathbf{W}. \quad (12.6)$$

其中下标 rw 表示 random walk, 因为 $\mathbf{D}^{-1} \mathbf{W}$ 可以解释为随机游走的转移概率矩阵。若存在孤立节点使 $d_i = 0$, 归一化前必须单独处理, 否则 $\mathbf{D}^{-1}$ 不存在。

12.6.3 从图割到特征向量

设节点集合被分为两个互不相交的部分 A 和 B 。两部分之间的割 (cut) 定义为

$$\text{cut}(A, B) = \sum_{i \in A} \sum_{j \in B} w_{ij}. \quad (12.7)$$

仅最小化 $\text{cut}(A, B)$ 容易产生一个极小簇, 例如单独切出一个弱连接节点。为鼓励较平衡的划分, 可以使用 RatioCut:

$$\text{RatioCut}(A_1, \dots, A_K) = \sum_{k=1}^K \frac{\text{cut}(A_k, \overline{A_k})}{|A_k|}, \quad (12.8)$$

或使用归一化割:

$$\text{Ncut}(A_1, \dots, A_K) = \sum_{k=1}^K \frac{\text{cut}(A_k, \overline{A_k})}{\text{vol}(A_k)}, \quad \text{vol}(A_k) = \sum_{i \in A_k} d_i. \quad (12.9)$$

直接寻找离散的最优图划分通常是困难的。谱聚类把离散簇指示变量放宽为连续向量, 从而把问题转化为带约束的二次型最小化。以二分类为例, 放松后的典型问题为

$$\min_{\mathbf{f}} \mathbf{f}^\top \mathbf{L} \mathbf{f}, \quad \mathbf{f}^\top \mathbf{1} = 0, \quad \|\mathbf{f}\|_2 = 1. \quad (12.10)$$

其解是 $\mathbf{L}$ 的第二小特征值对应的特征向量, 称为 Fiedler 向量。最小特征值对应常数向量, 只表示所有节点取相同值, 不能提供划分; 第二小特征向量则是在保持强连接节点取值接近的同时, 最容易发生变化的非平凡方向。根据其符号或阈值即可得到两个簇。

对于 K 个簇，需要取拉普拉斯矩阵最小的 K 个特征值对应的特征向量，将它们按列组成矩阵

$$\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_K] \in \mathbb{R}^{n \times K}.$$

矩阵 $\mathbf{U}$ 的第 i 行就是样本 $\mathbf{x}_i$ 的新表示。原始样本可能处于很高维或形成非凸结构，但在谱嵌入空间中，同一图连通区域的行向量通常更加接近。

12.6.4 一个四节点例子

考虑四个节点，其中节点 1,2 强连接，节点 3,4 强连接，两组之间只有强度为 ε 的弱边，且 $0 < \varepsilon \ll 1$ ：

$$\mathbf{W} = \begin{bmatrix} 0 & 1 & \varepsilon & 0 \\ 1 & 0 & 0 & \varepsilon \\ \varepsilon & 0 & 0 & 1 \\ 0 & \varepsilon & 1 & 0 \end{bmatrix}, \quad \mathbf{D} = (1 + \varepsilon)\mathbf{I}.$$

因此

$$\mathbf{L} = \begin{bmatrix} 1 + \varepsilon & -1 & -\varepsilon & 0 \\ -1 & 1 + \varepsilon & 0 & -\varepsilon \\ -\varepsilon & 0 & 1 + \varepsilon & -1 \\ 0 & -\varepsilon & -1 & 1 + \varepsilon \end{bmatrix}.$$

常数向量 $\mathbf{u}_1 = (1, 1, 1, 1)^\top$ 满足 $\mathbf{L}\mathbf{u}_1 = \mathbf{0}$ 。另取

$$\mathbf{u}_2 = (1, 1, -1, -1)^\top,$$

可以验证

$$\mathbf{L}\mathbf{u}_2 = 2\varepsilon\mathbf{u}_2. \quad (12.11)$$

当 ε 很小时， 2ε 是一个很小的非零特征值；对应特征向量在节点 1,2 上取正值，在节点 3,4 上取负值，恰好给出划分

$$\{1, 2\} \quad \text{和} \quad \{3, 4\}.$$


这个例子说明，小特征值对应图中容易被弱边分开的结构。

12.6.5 归一化谱聚类算法

实践中常使用基于 $\mathbf{L}_{\text{sym}}$ 的归一化谱聚类，其步骤如下：

1. 根据样本距离或任务相似性构造对称矩阵 $\mathbf{W}$ ；
2. 计算度矩阵 $\mathbf{D}$ 和归一化拉普拉斯矩阵 $\mathbf{L}_{\text{sym}}$ ；

3. 求 L_{sym} 最小的 K 个特征值对应的特征向量，组成 $U \in \mathbb{R}^{n \times K}$;
4. 将 U 的每一行归一化为单位长度，得到 Y ;
5. 把 Y 的第 i 行看作第 i 个样本的新表示，在这些行向量上运行 K-means;
6. 将 K-means 得到的簇标签返回给原始样本。



先用图结构学习表示，再在表示空间中聚类

图 12.2: 归一化谱聚类的计算流程。最终的 K-means 作用于拉普拉斯特征向量形成的谱嵌入，而不是原始特征。

12.6.6 参数、复杂度与使用边界

谱聚类的表现不仅取决于最后的 K-means，也高度依赖相似图。实际使用时需要注意：

- **特征尺度**：距离计算前应在训练数据上建立合理的标准化或表示，否则量纲较大的特征会支配图结构；
- **图参数**： k 、 ε 或高斯带宽过小会使图碎裂，过大则会连接原本不同的簇；
- **簇数**：通常仍需预先给定 K 。特征值之间明显的间隔（eigengap）可以作为参考，但不能替代领域判断；
- **计算成本**：完整相似矩阵需要 $O(n^2)$ 存储，特征分解在大样本下成本较高；可使用稀疏近邻图、迭代特征求解或 Nyström 近似；
- **可复现性**：特征向量的符号不唯一，最后的 K-means 也受初始化影响，应固定随机种子并报告多次运行结果。

谱聚类的优势是能够利用非凸、连通和流形结构；其代价是需要显式设计相似图，并进行矩阵特征分解。因此，它适合中小规模、样本关系比单一簇中心更重要的任务。

12.7 聚类评价指标：ARI、NMI、ACC 与 Silhouette

聚类没有统一的“正确答案”。评价前首先要明确是否存在可供比较的真实标签：

- **外部指标**：利用真实标签比较聚类结果，包括 ARI、NMI 和 ACC；
- **内部指标**：只根据样本和聚类结果评价簇内紧密、簇间分离等性质，Silhouette 是常见代表。

外部指标衡量“是否恢复已有标签”，内部指标衡量“当前表示和距离下的几何结构是否清晰”。两者回答的问题不同，不能相互替代。

12.7.1 列联表与标签置换

设真实类别划分为 $\mathcal{U} = \{U_1, \dots, U_R\}$ ，聚类结果为 $\mathcal{V} = \{V_1, \dots, V_C\}$ 。定义列联表元素

$$n_{rc} = |U_r \cap V_c|, \quad (12.12)$$

并定义行和、列和

$$a_r = \sum_{c=1}^C n_{rc}, \quad b_c = \sum_{r=1}^R n_{rc}, \quad n = \sum_{r=1}^R \sum_{c=1}^C n_{rc}.$$

其中 n_{rc} 表示真实类别 r 与聚类簇 c 共同包含的样本数。




图 12.3: 真实类别与聚类簇形成列联表。聚类编号本身没有语义，评价时不能直接把“簇 1”视为“真实类 1”。

例如，真实标签为 (A, A, A, B, B, B) ，聚类编号为 $(2, 2, 2, 1, 1, 1)$ 。虽然编号完全相反，但分组结构是正确的。ARI 和 NMI 天然不受编号置换影响；ACC 则必须先寻找最佳标签匹配。

12.7.2 ARI: 校正随机一致性的样本对指标

Rand Index 的思想是考察任意两个样本：真实标签和聚类结果是否同时把它们放在一起，或者同时把它们分开。ARI (adjusted Rand index) 在此基础上扣除了随机划分也可能产生的一致性。

在列联表中，落在同一单元格的任意两个样本，在真实标签和聚类结果中都属于同组，因此这种样本对数量为

$$\sum_{r=1}^R \sum_{c=1}^C \binom{n_{rc}}{2}.$$

真实类别中的同类样本对总数为 $\sum_r \binom{a_r}{2}$ ，聚类结果中的同簇样本对总数为 $\sum_c \binom{b_c}{2}$ 。ARI 定义为

$$\text{ARI} = \frac{\sum_{r,c} \binom{n_{rc}}{2} - \frac{\left(\sum_r \binom{a_r}{2}\right) \left(\sum_c \binom{b_c}{2}\right)}{\binom{n}{2}}}{\frac{1}{2} \left[\sum_r \binom{a_r}{2} + \sum_c \binom{b_c}{2} \right] - \frac{\left(\sum_r \binom{a_r}{2}\right) \left(\sum_c \binom{b_c}{2}\right)}{\binom{n}{2}}}. \quad (12.13)$$

ARI 等于 1 表示两个划分完全一致；接近 0 表示与随机划分的期望水平相近；在某些情况下可以为负，表示一致性比随机期望还差。ARI 对簇编号置换不敏感，但在簇数、簇规模高度不均衡时仍应结合其他指标解释。

12.7.3 NMI: 聚类结果共享了多少标签信息

NMI (normalized mutual information) 从信息论角度评价真实标签 U 与聚类标签 V 的关联。由列联表定义概率

$$p_{rc} = \frac{n_{rc}}{n}, \quad p_r = \frac{a_r}{n}, \quad q_c = \frac{b_c}{n}.$$

互信息为

$$I(U; V) = \sum_{r=1}^R \sum_{c=1}^C p_{rc} \log \frac{p_{rc}}{p_r q_c}, \quad (12.14)$$

其中约定 $p_{rc} = 0$ 的项贡献为 0。真实标签和聚类标签的熵分别为

$$H(U) = - \sum_{r=1}^R p_r \log p_r, \quad H(V) = - \sum_{c=1}^C q_c \log q_c.$$

一种常用归一化方式为

$$\text{NMI}(U, V) = \frac{2I(U; V)}{H(U) + H(V)}. \quad (12.15)$$

NMI 通常位于 $[0, 1]$ ：越接近 1，说明聚类结果包含越多真实标签信息。不同软件可能采用 $I/\sqrt{H(U)H(V)}$ 等其他归一化方式，因此报告结果时应说明实现或软件版本。

NMI 不要求簇编号与类别编号对齐，也比直接准确率更适合比较分组结构；但普通 NMI 没有像 ARI 那样完全校正有限样本下的随机一致性，在簇数很多时可能产生偏高倾向。

12.7.4 ACC：最佳标签匹配后的准确率

设聚类算法给出的簇标签为 c_i ，真实标签为 y_i 。由于簇编号可以任意交换，聚类准确率 ACC 定义为

$$\text{ACC} = \max_{\pi} \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{y_i = \pi(c_i)\}, \quad (12.16)$$

其中 π 是簇编号到真实类别编号的一个置换， $\mathbb{I}\{\cdot\}$ 是指示函数。实践中通常根据列联表使用匈牙利算法寻找总匹配数最大的映射。

若簇数和真实类别数不同，需要先明确如何处理未匹配的簇或类别。ACC 直观易懂，但依赖真实标签，而且把每个样本是否匹配压缩成 0/1，无法像 NMI 那样表达信息共享程度。

12.7.5 Silhouette：簇内紧密与簇间分离

Silhouette（轮廓系数）不需要真实标签。对于样本 i ，设它所属的簇为 C_i 。它到同簇其他样本的平均距离为

$$a(i) = \frac{1}{|C_i| - 1} \sum_{\substack{j \in C_i \\ j \neq i}} d(\mathbf{x}_i, \mathbf{x}_j), \quad (12.17)$$

表示簇内不紧密程度。样本 i 到另一个簇 $C \neq C_i$ 的平均距离为

$$\delta(i, C) = \frac{1}{|C|} \sum_{j \in C} d(\mathbf{x}_i, \mathbf{x}_j).$$

取其中最小值

$$b(i) = \min_{C \neq C_i} \delta(i, C), \quad (12.18)$$

作为样本到“最近其他簇”的平均距离。样本 i 的轮廓系数为

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}. \quad (12.19)$$

由式 (12.19) 可知， $s(i) \in [-1, 1]$ ：

- $s(i)$ 接近 1： $a(i) \ll b(i)$ ，样本与本簇紧密且远离其他簇；
- $s(i)$ 接近 0：样本可能位于簇边界；
- $s(i) < 0$ ：样本到其他簇平均距离更小，可能被分错。




图 12.4: 轮廓系数比较样本的簇内平均距离 $a(i)$ 与最近其他簇平均距离 $b(i)$ 。图中连线仅表示这两个平均量的方向。

整个数据集的 Silhouette 得分通常取 n 个样本轮廓系数的平均值。对于单样本簇，式 (12.17) 无法正常计算，常见软件通常将其轮廓系数设为 0。Silhouette 依赖所选距离，并偏好簇内紧密、簇间分离的结构；对非凸簇、密度差异较大的簇可能给出不符合领域直觉的评价。

12.7.6 四种指标的比较与报告建议

表 12.1: 常见聚类评价指标的比较

指标	是否需要真实标签	主要衡量内容	需要注意的问题
ARI	需要	样本对的分组一致性，并校正随机期望	受簇规模和簇数结构影响，可能为负
NMI	需要	聚类标签与真实标签共享的信息	存在不同归一化定义，簇数很多时可能偏高
ACC	需要	最佳标签匹配后的样本准确率	必须先做标签置换匹配；簇数不同时需说明规则
Silhouette	不需要	簇内紧密程度与簇间分离程度	依赖距离和簇形状，对非凸或不同密度簇可能不理想

聚类实验不应只报告一个分数。较稳妥的做法是：

1. 有真实标签时，同时报告至少一种随机校正指标（如 ARI）和一种信息或样本级指标（如 NMI、ACC）；
2. 无真实标签时，将 Silhouette 与可视化、簇规模、领域解释和下游任务表现结合；
3. 对 K-means、谱聚类等含随机步骤的方法，使用多个随机种子并报告均值和标准差；

4. 在验证阶段选择簇数、图参数和距离度量，避免根据最终测试标签反复调参；
5. 检查小簇、孤立点和不稳定样本，而不仅观察全局平均分数。

本节四个指标分别从样本对、信息共享、标签匹配和几何分离四个角度观察聚类。真实标签也未必代表唯一合理的分组方式，因此评价结果最终还需回到任务目标：这些簇是否稳定、可解释，并能支持后续研究或应用。